

ANÁLISE DE VOTAÇÃO PARLAMENTAR COM INTELIGÊNCIA ARTIFICIAL: ADERÊNCIA IDEOLÓGICA

Sarpa, Mauricio
Engenharia da Computação
Fundação Hermínio Ometto
Araras, Brasil
sarpa@alunos.fho.edu.br

Ramos Novais, Pablo
Engenharia da Computação
Fundação Hermínio Ometto
Araras, Brasil
pablo@alunos.fho.edu.br

Resumo—A análise da votação nominal no legislativo é crucial para a transparência. Contudo, a coerência de voto é complexa devido à politização dos temas. Métodos estatísticos tradicionais têm limitações em capturar a natureza multifatorial dessas decisões. Propomos o desenvolvimento de um sistema de Inteligência Artificial para comparar o voto real de deputados e senadores com um voto esperado, inferido por sua classificação política. A principal contribuição é um algoritmo que quantifica a aderência ideológica e partidária, oferecendo uma métrica contínua e objetiva sobre a coerência política no legislativo brasileiro.

Index Terms—Inteligência Artificial, Ciência Política, Análise de Voto, Politização, Machine Learning.

I. INTRODUÇÃO

A análise da **votação nominal** em casas legislativas é fundamental para a **transparência política** e a mensuração da ideologia parlamentar. Contudo, a efetiva coerência de voto é frequentemente desafiada pela **politização** dos temas, que eleva o debate da esfera técnica para a **esfera ideológica e partidária**, influenciando diretamente a disciplina de voto e o alinhamento esperado [1].

Os métodos estatísticos tradicionais, como o uso de Componentes Principais [2], têm limitações em capturar essa complexidade e a natureza multifatorial das decisões legislativas, especialmente com o grande volume de **dados abertos** disponíveis [3]. Motivado por essa lacuna, este projeto propõe o uso de **Inteligência Artificial (IA)** e *Machine Learning* para desenvolver ferramentas analíticas mais robustas.

Nosso objetivo central é criar um sistema de IA que **compare o voto real** dos deputados e senadores com um **voto esperado**, inferido a partir da sua classificação política e ideológica, mensurando a influência da politização no comportamento legislativo. A principal **contribuição** deste trabalho reside na criação de um **algoritmo de classificação** que oferece uma métrica objetiva e contínua para quantificar a **aderência ideológica/partidária** dos representantes, fornecendo uma nova lente para entender a dinâmica de conflito e a coerência política no legislativo brasileiro.

II. TRABALHOS RELACIONADOS

A análise quantitativa de votações nominais constitui o alicerce para a mensuração da ideologia e da disciplina partidária no legislativo. Historicamente, o *state of the art* nesse campo se concentra em métodos de redução de dimensionalidade para mapear as posições ideológicas dos parlamentares em um espaço de baixa dimensão.

A. Modelos Clássicos e Votações Nominais

Uma das abordagens mais consolidadas na literatura brasileira é o uso da Análise de Componentes Principais (ACP), ou PCA. Leite e Trento [2] descrevem e validam o PCA para a análise de votações nominais no Brasil, um contexto onde as abstenções e as análises agregadas por partido são cruciais. Os autores demonstram a eficácia do PCA em relação ao modelo W-NOMINATE, estabelecendo o tratamento dos votos ('+1' para sim, '-1' para não, '0' para neutro) como um padrão robusto para a construção de matrizes de votação, o mesmo esquema adotado neste trabalho.

Embora o PCA seja eficaz para posicionar os parlamentares em um espectro ideológico, sua limitação reside na capacidade de capturar a dinâmica da coesão e da indisciplina de voto, especialmente em cenários de alta **politização** [1]. Buscando aprimorar a identificação desses padrões, Kreuch [5] explora o uso de outras técnicas de redução de dimensionalidade (como MDS, t-SNE e UMAP) combinadas com algoritmos de agrupamento mais avançados (como HDBSCAN e Propagação por Afinidade) para identificar a formação de coalizões e a evolução dos agrupamentos ideológicos ao longo do tempo. Esse trabalho reforça a relevância das técnicas de *clustering* para a análise de coesão, premissa fundamental para a metodologia proposta.

B. Análise de Conteúdo e a Lacuna da Aderência

O debate sobre a verdadeira natureza da ideologia parlamentar levou a estudos que buscam mensurá-la a partir de fontes alternativas. Lima [3] utiliza o Processamento de Linguagem Natural (PLN) e *Machine Learning* para analisar as relações entre partidos e a coesão ideológica baseada em **discursos**

no Congresso Nacional. A motivação para analisar discursos reside na premissa de que a linguagem utilizada pode revelar diferenças intrapartidárias e ideológicas que são mascaradas pela disciplina partidária nos votos nominais.

Neste contexto, o presente trabalho se insere na lacuna identificada pela literatura. Enquanto os modelos existentes focam em *descrever* o voto real (PCA) ou em inferir a ideologia a partir de *discursos* (PLN), inexistente uma métrica contínua e objetiva que **quantifique a aderência** de um parlamentar ao seu **voto esperado** ou ideal. Propomos, portanto, um algoritmo que utiliza o K-means não apenas para mapear, mas para **modelar o voto ideal** de cada agrupamento, permitindo a comparação direta com o voto real do indivíduo. Essa abordagem inova ao fornecer um indicador direto e contínuo da coerência política e da influência da **politização** na tomada de decisão.

III. METODOLOGIA PROPOSTA

A metodologia deste trabalho é estruturada em um pipeline de ciência de dados, compreendendo a aquisição e tratamento dos dados, a aplicação de um modelo de aprendizado não supervisionado para identificação de padrões e, por fim, a validação rigorosa dos resultados obtidos.

A. Coleta e Estruturação dos Dados

A fonte primária de dados é a API de Dados Abertos do Senado Federal, que disponibiliza o histórico de votações em formato JSON. O processo de coleta é realizado de forma programática, seguindo uma sequência de requisições para obter os votos individuais de cada senador em cada votação. Primeiramente, os dados brutos são transformados em uma **matriz senador-votação**, na qual cada linha representa um senador e cada coluna, uma votação específica.

Os valores categóricos dos votos ('Sim', 'Não', 'Abstenção', etc.) são convertidos para um formato numérico, seguindo um esquema de codificação consolidado na análise legislativa brasileira [2]:

- **Sim:** +1
- **Não:** -1
- **Abstenção, Obstrução, Ausência ou Presidente:** 0

Diferentemente de abordagens tradicionais que aplicam normalização (como Z-score) aos dados, optou-se por utilizar os valores brutos da codificação proposta. Esta decisão fundamenta-se na necessidade de preservar o valor zero como um ponto fixo de neutralidade (abstenção ou ausência), garantindo que a interpretação geométrica da distância em relação à origem permaneça semanticamente coerente com a posição de não-voto.

Um passo crítico no pré-processamento é a filtragem das votações. Seguindo a recomendação de Ribeiro (2023), apenas votações **substantivas** (de mérito) são mantidas, enquanto votações puramente **procedimentais** são descartadas. Essa distinção é crucial para evitar que o modelo agrupe os parlamentares com base em táticas regimentares (ruído) em vez de seus posicionamentos ideológicos (sinal) [1].

Adicionalmente, foram aplicados dois critérios de filtragem para garantir a qualidade estatística da matriz de dados. Primeiro, foram excluídas as votações unânimes, uma vez que a ausência de variância nesses registros não contribui para a discriminação de agrupamentos (clusters). Segundo, estabeleceu-se um critério de assiduidade mínima: parlamentares com participação inferior a 50% nas votações do período analisado foram removidos da amostra. Esta medida visa mitigar a esparsidade excessiva dos vetores de votação, que poderia introduzir ruído no cálculo das distâncias euclidianas.

B. Modelo de Agrupamento: K-Means

Para identificar os agrupamentos latentes de senadores, foi selecionado o algoritmo de clusterização **K-means**, um método de aprendizado não supervisionado. O K-means particiona o conjunto de dados em K clusters distintos, buscando minimizar a inércia, também conhecida como Soma dos Quadrados Dentro do Cluster (WCSS - *Within-Cluster Sum of Squares*). A inércia é definida como:

$$\sum_{i=0}^n \min_{\mu_j \in C} (||x_i - \mu_j||^2)$$

onde x_i é o vetor de votos de um senador e μ_j é o centróide (ponto médio) do cluster C_j .

O algoritmo opera iterativamente em duas etapas:

- 1) **Atribuição:** Cada senador (ponto de dado) é atribuído ao cluster cujo centróide é o mais próximo, com base na distância euclidiana.
- 2) **Atualização:** O centróide de cada cluster é recalculado como a média dos vetores de todos os senadores atribuídos a ele.

Essas etapas são repetidas até a convergência, quando as atribuições de cluster não se alteram mais. Para a inicialização dos centróides, utiliza-se o método *K-means++*, que melhora a qualidade dos resultados e acelera a convergência.

C. Validação e Otimização do Modelo

A escolha do número ótimo de clusters (K) é um parâmetro fundamental e não arbitrário. A determinação do número ótimo de clusters (K) não se baseou em uma única métrica. Adotou-se uma abordagem de validação cruzada por múltiplos índices para mitigar vieses específicos de cada algoritmo. Além do Método do Cotovelo e da Análise de Silhueta, foram calculados os índices Davies-Bouldin (onde menores valores indicam melhor separação) e Calinski-Harabasz (onde maiores valores indicam clusters mais densos).

O valor final de K foi definido através de um sistema de consenso (votação majoritária) entre as métricas sugeridas por cada índice, selecionando o número de agrupamentos que apresentou maior estabilidade entre os diferentes métodos de avaliação.

D. Algoritmo de Classificação para Aderência Ideológica

A principal contribuição deste trabalho reside no desenvolvimento de um algoritmo que transforma a saída do modelo K-means (o agrupamento ideológico) em uma métrica de **Aderência Ideológica** (AI) contínua e interpretável.

1) *Definição do Voto Esperado*: Após a clusterização da matriz senador-votação pelo K-means, cada um dos K clusters (C_j) representa uma **posição ideológica latente**. O centróide do cluster (μ_j) corresponde ao vetor de votos médios do grupo em todas as votações. Para definir o **Voto Esperado** ($\hat{v}_j$) desse grupo, o centróide é binarizado (ou trinarizado) por meio de um limiar (τ).

O **Voto Esperado do Cluster** ($\hat{v}_j^{(i)}$) para uma votação i é dado por:

$$\hat{v}_j^{(i)} = \begin{cases} +1 & \text{se } \mu_j^{(i)} > \tau \\ -1 & \text{se } \mu_j^{(i)} < -\tau \\ 0 & \text{se } -\tau \leq \mu_j^{(i)} \leq \tau \end{cases}$$

onde τ é um limiar de neutralidade definido empiricamente neste estudo como $\tau = 0.1$. Este limiar estabelece uma zona de neutralidade mais robusta, assegurando que apenas tendências majoritárias claras no cluster sejam classificadas como Voto Esperado (+1 ou -1), enquanto médias próximas a zero (indicativas de dispersão interna no grupo) permanecem classificadas como neutras.

2) *Cálculo da Aderência Ideológica (AI)*: A métrica AI quantifica a coerência do senador i em relação à posição ideológica ideal de seu grupo C_{ideal} . Essa aderência é calculada utilizando a **Similaridade de Cosseno** entre o vetor de voto real do senador (x_i) e o vetor de voto esperado de seu cluster ($\hat{v}_{ideal}$), sendo o cluster C_{ideal} aquele ao qual o senador foi atribuído pelo K-means.

A Similaridade de Cosseno é definida como:

$$AI_i = \text{Similaridade}(x_i, \hat{v}_{ideal}) = \frac{x_i \cdot \hat{v}_{ideal}}{\|x_i\| \|\hat{v}_{ideal}\|}$$

O resultado é um valor contínuo que varia de -1 (totalmente oposto ao voto esperado) a +1 (aderência perfeita), oferecendo um índice robusto de quão bem o parlamentar se alinha ao seu agrupamento ideológico.

IV. RESULTADOS E DISCUSSÃO

A aplicação do pipeline de orquestração permitiu processar os dados de votações nominais do Senado Federal referente ao ano de 2023. A seguir, detalham-se as etapas de redução de dimensionalidade, a determinação do número ótimo de clusters e a análise aprofundada da aderência ideológica.

A. Pré-processamento e Redução de Dimensionalidade

A coleta inicial retornou 141 votações. Após a filtragem metodológica — removendo votações de homenagens, pesar e aquelas com unanimidade (baixa variância) —, restaram 35 votações significativas para a análise. O dataset final contou com 81 senadores ativos (participação superior a 50%).

A análise descritiva revelou uma esparsidade de 17,60%, indicando um preenchimento consistente da matriz de votos. A aplicação da Análise de Componentes Principais (PCA) reduziu as 35 dimensões originais (votações) para 19 componentes principais, preservando 95% da variância explicada dos dados.

B. Determinação do Número de Clusters (K)

Para definir o número ideal de agrupamentos, o algoritmo K-Means foi executado com K variando de 2 a 10. As métricas de validação são detalhadas na Tabela I e visualizadas na Figura 1.

Tabela I
MÉTRICAS DE VALIDAÇÃO PARA DIFERENTES VALORES DE K

K	Inércia	Silhueta	Davies-Bouldin
2	1671.65	0.3205	1.2530
3	1375.97	0.2439	1.4711
4	1253.96	0.1948	1.7596
5	1190.74	0.1977	1.7831




Figura 1. Comportamento das métricas de validação. Nota-se que $K=3$ mantém estabilidade antes da queda acentuada de desempenho em $K=4$.

A análise da Figura 1 revela que, embora $K = 2$ apresente os melhores indicadores absolutos (sugerindo polarização binária), a transição para $K = 3$ não representa uma perda estrutural crítica. O índice de Silhueta em $K = 3$ (0.2439) permanece significativamente superior ao patamar observado em $K = 4$ (0.1948), onde ocorre uma degradação acentuada da coesão dos grupos.

Portanto, $K = 3$ configura-se como um ponto de inflexão: ele oferece uma redução substancial na Inércia (de 1671 para 1375) em comparação a $K = 2$, sem sofrer a pulverização excessiva observada em $K \geq 4$. Essa característica matemática valida a escolha manual de três clusters, permitindo capturar a complexidade do espectro político (Governo, Oposição e Centro) que seria ignorada em uma abordagem puramente binária.

C. Caracterização dos Agrupamentos

Com $K = 3$, os perfis foram definidos como:

- **Cluster 0 (Governo)**: 25 membros, alta coesão (Aderência média: 0.471). Predominância de PT, PSD e MDB.
- **Cluster 1 (Oposição)**: 27 membros, média coesão (Aderência média: 0.419). Predominância de PL, PP e Republicanos.

- **Cluster 2 (Centro/Independente):** 29 membros, baixa coesão (Aderência média: 0.258). Grupo heterogêneo com membros de PSD, União e Podemos.

D. Análise de Aderência Ideológica (AI)

A métrica de Aderência Ideológica (AI) permitiu classificar os senadores quanto à fidelidade ao comportamento médio de seu grupo.

A Tabela II apresenta os 15 parlamentares com maior aderência. Nota-se que senadores do PP e PL dominam o topo da lista de fidelidade no Cluster 1, enquanto o PT e aliados demonstram forte alinhamento no Cluster 0. O senador Luis Carlos Heinze (PP) obteve a maior aderência absoluta (0.7588).

Tabela II
TOP 15 PARLAMENTARES COM MAIOR ADERÊNCIA

Parlamentar	Partido	Cluster	Aderência (AI)
Luis Carlos Heinze	PP	1	0.7588
Eliziane Gama	PSD	0	0.6857
Wilder Moraes	PL	1	0.6583
Tereza Cristina	PP	1	0.6564
Beto Faro	PT	0	0.6560
Randolfe Rodrigues	REDE	0	0.6560
Fabiano Contarato	PT	0	0.6560
Paulo Paim	PT	0	0.6560
Jussara Lima	PSD	0	0.6534
Rogério Carvalho	PT	0	0.6527
Augusta Brito	PT	0	0.6477
Rogério Marinho	PL	1	0.6358
Romário	PL	1	0.6209
Professora Dorinha Seabra	UNIÃO	2	0.5852
Marcelo Castro	MDB	0	0.5735

Por outro lado, a Tabela III destaca os parlamentares com menor aderência. É notável a presença massiva de membros do Cluster 2 (Centro) nesta lista. Senadores como Oriovisto Guimarães e Laércio Oliveira apresentaram valores de aderência negativos, indicando que seus votos frequentemente divergem do centroide do seu próprio grupo, validando a hipótese de que o "Centro" não opera como um bloco monolítico, mas sim como uma zona de convergência flutuante.

Tabela III
TOP 15 PARLAMENTARES COM MENOR ADERÊNCIA

Parlamentar	Partido	Cluster	Aderência (AI)
Oriovisto Guimarães	PODEMOS	2	-0.1426
Laércio Oliveira	PP	2	-0.1348
Vanderlan Cardoso	PSD	2	-0.1241
Alan Rick	UNIÃO	2	-0.0243
Soraya Thronicke	UNIÃO	2	0.0045
Zequinha Marinho	PL	2	0.0252
Rodrigo Pacheco	PSD	2	0.0745
Carlos Viana	PODEMOS	2	0.0921
Styverson Valentim	PODEMOS	2	0.0938
Alessandro Vieira	PSDB	2	0.1268
Marcio Bittar	UNIÃO	1	0.1372
Marcos Rogério	PL	1	0.1794
Marcos do Val	PODEMOS	1	0.1836
Mara Gabrilli	PSD	2	0.1862
Sergio Moro	UNIÃO	1	0.2130

V. CONCLUSÃO

O presente trabalho atingiu seu objetivo central ao desenvolver e aplicar uma metodologia baseada em Inteligência Artificial para mensurar a aderência ideológica no Senado Federal. A utilização do algoritmo K-Means, combinada com métricas de validação e uma análise qualitativa do cenário político, permitiu transcender a análise puramente estatística, oferecendo uma interpretação computacional da dinâmica parlamentar.

Os resultados obtidos ratificam a hipótese de que a polarização política brasileira, embora matematicamente binária (como sugerido pelos índices de Silhueta para $K = 2$), exige uma modelagem tricotômica para representar a realidade fática. A decisão estratégica de fixar $K = 3$ revelou-se acertada ao isolar um terceiro agrupamento ("Centro") cuja característica definidora não é a coesão, mas a dispersão. Enquanto os clusters de Governo e Oposição apresentaram altas taxas de aderência ideológica (médias de 0.47 e 0.41, respectivamente), o Cluster 2 demonstrou uma aderência significativamente menor (0.25) e diversos valores negativos. Isso valida computacionalmente o conceito de "Centrão" como uma zona de convergência flutuante, e não como um bloco ideológico monolítico.

A principal contribuição técnica deste estudo é a formalização da métrica de **Aderência Ideológica (AI)**. Ao quantificar a fidelidade do parlamentar em uma escala contínua, o sistema oferece uma ferramenta objetiva para identificar tanto os líderes de núcleo duro (como demonstrado no Cluster 1) quanto os parlamentares pendulares.

A. Limitações e Desafios

Uma limitação inerente ao estudo foi definir o limiar de neutralidade (τ) e a escolha do número de clusters exigiu uma intervenção humana supervisionada sobre o modelo não supervisionado. Embora matematicamente justificada pela estabilidade da silhueta em $K = 3$, essa etapa sublinha que a IA, neste contexto, atua melhor como uma ferramenta de suporte à decisão do analista político do que como um oráculo totalmente autônomo.

B. Trabalhos Futuros

Para extensões futuras, sugere-se a aplicação desta metodologia em uma série temporal longitudinal, abrangendo múltiplas legislaturas, para visualizar a migração de parlamentares entre clusters (mudança de aderência) ao longo do tempo. Outra via promissora é a integração de técnicas de Processamento de Linguagem Natural (PLN) para correlacionar a aderência ideológica votada (o que o senador faz) com a aderência discursiva (o que o senador fala em tribuna), permitindo identificar dissonâncias entre o discurso e a prática legislativa.

Em suma, a ferramenta desenvolvida demonstra que a aplicação de aprendizado de máquina em dados governamentais abertos é um caminho viável e robusto para aumentar a transparência e a compreensibilidade do complexo jogo democrático.

REFERÊNCIAS

- [1] RIBEIRO, T. D. *Por que um deputado é indisciplinado?: uma análise das votações nominais na câmara dos deputados entre os anos de 2015 e 2022*. 2023. Dissertação (Mestrado em Administração Pública) – Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa, Brasília, 2023.
- [2] LEITE, L.; TRENTO, S. Análise de votações nominais do legislativo brasileiro utilizando componentes principais. *Leviathan: Cadernos de Pesquisa Política*, n. 12, p. 120-163, 2016.
- [3] LIMA, W. P. C. *Uma análise de partidos políticos baseada em discursos no congresso nacional brasileiro*. 2023. Dissertação (Mestrado em Ciência da Computação) – Centro Federal de Educação Tecnológica Celso Suckow da Fonseca, Rio de Janeiro, 2023.
- [4] ROUSSEEUW, P. J. Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis. *Journal of Computational and Applied Mathematics*, v. 20, p. 53-65, 1987.
- [5] KREUCH, M. A. *Desenvolvimento de solução para visualização e análise de votações políticas*. 2024. Trabalho de Conclusão de Curso (Graduação em Ciências da Computação) – Universidade Federal de Santa Catarina, Florianópolis, 2024.