

ANÁLISE DE VOTAÇÃO PARLAMENTAR COM INTELIGÊNCIA ARTIFICIAL: ADERÊNCIA IDEOLÓGICA

Sarpa, Mauricio
Engenharia da Computação
Fundação Hermínio Ometto
Araras, Brasil
sarpa@alunos.fho.edu.br

Ramos Novais, Pablo
Engenharia da Computação
Fundação Hermínio Ometto
Araras, Brasil
pablo@alunos.fho.edu.br

Resumo—A análise da votação nominal no legislativo é crucial para a transparência. Contudo, a coerência de voto é complexa devido à politização dos temas. Métodos estatísticos tradicionais têm limitações em capturar a natureza multifatorial dessas decisões. Propomos o desenvolvimento de um sistema de Inteligência Artificial para comparar o voto real de deputados e senadores com um voto esperado, inferido por sua classificação política. A principal contribuição é um algoritmo que quantifica a aderência ideológica e partidária, oferecendo uma métrica contínua e objetiva sobre a coerência política no legislativo brasileiro. Os resultados validaram a existência de três agrupamentos distintos, revelando matematicamente a baixa coesão ideológica dos parlamentares de centro em comparação à polarização governo-oposição.

Index Terms—Inteligência Artificial, Ciência Política, Análise de Voto, Politização, Machine Learning.

I. INTRODUÇÃO

A análise da **votação nominal** em casas legislativas é fundamental para a **transparência política** e a mensuração da ideologia parlamentar. Contudo, a efetiva coerência de voto é frequentemente desafiada pela **politização** dos temas, que eleva o debate da esfera técnica para a **esfera ideológica e partidária**, influenciando diretamente a disciplina de voto e o alinhamento esperado [2].

Os métodos estatísticos tradicionais, como o uso de Componentes Principais [3], têm limitações em capturar essa complexidade e a natureza multifatorial das decisões legislativas, especialmente com o grande volume de **dados abertos** disponíveis [4]. Motivado por essa lacuna, este projeto propõe o uso de **Inteligência Artificial (IA)** e *Machine Learning* para desenvolver ferramentas analíticas mais robustas.

Nosso objetivo central é criar um sistema de IA que **compare o voto real** dos deputados e senadores com um **voto esperado**, inferido a partir da sua classificação política e ideológica, mensurando a influência da politização no comportamento legislativo. A principal **contribuição** deste trabalho reside na criação de um **algoritmo de classificação** que oferece uma métrica objetiva e contínua para quantificar a **aderência ideológica/partidária** dos representantes, forne-

cendo uma nova lente para entender a dinâmica de conflito e a coerência política no legislativo brasileiro.

II. TRABALHOS RELACIONADOS

A análise quantitativa de votações nominais constitui o alicerce para a mensuração da ideologia e da disciplina partidária no legislativo. Historicamente, o *state of the art* nesse campo se concentra em métodos de redução de dimensionalidade para mapear as posições ideológicas dos parlamentares em um espaço de baixa dimensão.

A. Modelos Clássicos para Mapeamento Ideológico

Uma das abordagens mais consolidadas na literatura brasileira para a análise de votações nominais é a **Análise de Componentes Principais (ACP)**, ou PCA. Leite e Trento [3] descrevem e validam o PCA para o contexto brasileiro, onde o tratamento dos votos (codificação +1, -1, 0) e das abstenções é crucial. O PCA é altamente eficaz em posicionar os parlamentares em um espectro ideológico contínuo, geralmente bidimensional, permitindo uma visualização clara da polarização. Contudo, a limitação central do PCA reside em sua natureza **descritiva**: ele mapeia o voto real, mas não é desenhado para *quantificar a coesão* interna ou a *aderência* individual a um comportamento de grupo preestabelecido. Em cenários de alta **politização**, onde a disciplina de voto é o foco, o PCA pode mascarar dinâmicas de indisciplina intrapartidária [2].

B. Abordagens de Agrupamento (Clustering) e Discurso

Buscando aprimorar a identificação de padrões de coesão, a literatura tem explorado o uso de técnicas de agrupamento (*clustering*). Kreuch [6] explora técnicas avançadas de redução de dimensionalidade (como t-SNE e UMAP) combinadas com algoritmos de *clustering* (como HDBSCAN e Propagação por Afinidade) para identificar a formação de coalizões e a evolução de agrupamentos ideológicos ao longo do tempo. Esse foco no *clustering* reforça a premissa de que a identificação de grupos coesos é um passo fundamental para a análise de

disciplina, diferentemente do mapeamento ideológico contínuo do PCA.

Adicionalmente, o debate sobre a natureza da ideologia parlamentar levou a estudos que analisam fontes alternativas. Lima [4] utiliza o Processamento de Linguagem Natural (PLN) e *Machine Learning* para analisar as relações ideológicas baseadas em **discursos** no Congresso Nacional. A motivação é inferir ideologias que são potencialmente *mascaradas* pela disciplina partidária exigida nas votações nominais, buscando capturar diferenças sutis que o voto final não revela.

C. A Lacuna da Métrica Contínua de Aderência

Neste contexto, o presente trabalho insere-se na lacuna identificada pela literatura. Enquanto os modelos existentes focam em:

- 1) **Descrever** o voto real em um espectro (PCA [3]),
- 2) **Identificar** grupos de voto coeso (*Clustering* [6]), ou
- 3) **Inferir** a ideologia a partir de *discursos* (PLN [4]),

inexiste uma métrica contínua e objetiva que **quantifique a aderência** de um parlamentar ao seu **voto esperado** ou ideal de grupo. Propomos, portanto, um algoritmo que utiliza o K-means não apenas para mapear, mas para **modelar o voto ideal** de cada agrupamento (através do centróide trinarizado), permitindo a comparação direta com o vetor de voto real do indivíduo através da **Similaridade de Cosseno**. Essa abordagem inova ao fornecer um indicador direto e contínuo da **coerência política** e da influência da **politização** na tomada de decisão, que não se restringe à mera identificação do grupo, mas sim à medição da fidelidade a ele.

III. METODOLOGIA PROPOSTA

A metodologia deste trabalho é estruturada em um pipeline de ciência de dados, compreendendo a aquisição e tratamento dos dados, a aplicação de um modelo de aprendizado não supervisionado para identificação de padrões e, por fim, a validação rigorosa dos resultados obtidos.

A. Coleta e Estruturação dos Dados

A fonte primária de dados é a API de Dados Abertos do Senado Federal, que disponibiliza o histórico de votações em formato JSON. O processo de coleta é realizado de forma programática, seguindo uma sequência de requisições para obter os votos individuais de cada senador em cada votação. Primeiramente, os dados brutos são transformados em uma **matriz senador-votação**, na qual cada linha representa um senador e cada coluna, uma votação específica.

Os valores categóricos dos votos ('Sim', 'Não', 'Abstenção', etc.) são convertidos para um formato numérico, seguindo um esquema de codificação consolidado na análise legislativa brasileira [3]:

- **Sim:** +1
- **Não:** -1
- **Abstenção, Obstrução, Ausência ou Presidente:** 0

Diferentemente de abordagens tradicionais que aplicam normalização (como Z-score) aos dados, optou-se por utilizar os valores brutos da codificação proposta. Esta decisão

fundamenta-se na necessidade de preservar o valor zero como um ponto fixo de neutralidade (abstenção ou ausência), garantindo que a interpretação geométrica da distância em relação à origem permaneça semanticamente coerente com a posição de não-voto.

Um passo crítico no pré-processamento é a filtragem das votações. Seguindo a recomendação de Ribeiro (2023), apenas votações **substantivas** (de mérito) são mantidas, enquanto votações puramente **procedimentais** são descartadas. Essa distinção é crucial para evitar que o modelo agrupe os parlamentares com base em táticas regimentares (ruído) em vez de seus posicionamentos ideológicos (sinal) [2].

Adicionalmente, foram aplicados dois critérios de filtragem para garantir a qualidade estatística da matriz de dados. Primeiro, foram excluídas as votações unânimes, uma vez que a ausência de variância nesses registros não contribui para a discriminação de agrupamentos (clusters). Segundo, estabeleceu-se um critério de assiduidade mínima: parlamentares com participação inferior a 50% nas votações do período analisado foram removidos da amostra. Esta medida visa mitigar a esparsidade excessiva dos vetores de votação, que poderia introduzir ruído no cálculo das distâncias euclidianas.

B. Modelo de Agrupamento: K-Means

Para identificar os agrupamentos latentes de senadores, foi selecionado o algoritmo de clusterização **K-means**, um método de aprendizado não supervisionado. O K-means particiona o conjunto de dados em K clusters distintos, buscando minimizar a inércia, também conhecida como Soma dos Quadrados Dentro do Cluster (WCSS - *Within-Cluster Sum of Squares*). A inércia é definida como:

$$\sum_{i=0}^n \min_{\mu_j \in C} (||x_i - \mu_j||^2)$$

onde x_i é o vetor de votos de um senador e μ_j é o centróide (ponto médio) do cluster C_j .

O algoritmo opera iterativamente em duas etapas:

- 1) **Atribuição:** Cada senador (ponto de dado) é atribuído ao cluster cujo centróide é o mais próximo, com base na distância euclidiana.
- 2) **Atualização:** O centróide de cada cluster é recalculado como a média dos vetores de todos os senadores atribuídos a ele.

Essas etapas são repetidas até a convergência, quando as atribuições de cluster não se alteram mais. Para a inicialização dos centróides, utiliza-se o método *K-means++*, que melhora a qualidade dos resultados e acelera a convergência.

C. Validação e Otimização do Modelo

A escolha do número ótimo de clusters (K) é um parâmetro fundamental e não arbitrário. A determinação do número ótimo de clusters (K) não se baseou em uma única métrica. Adotou-se uma abordagem de validação cruzada por múltiplos índices para mitigar vieses específicos de cada algoritmo. Além do Método do Cotovelo e da Análise de Silhueta, foram calculados os índices Davies-Bouldin (onde menores valores

indicam melhor separação) e Calinski-Harabasz (onde maiores valores indicam clusters mais densos).

O valor final de K foi definido através de um sistema de consenso (votação majoritária) entre as métricas sugeridas por cada índice, selecionando o número de agrupamentos que apresentou maior estabilidade entre os diferentes métodos de avaliação.

D. Algoritmo de Classificação para Aderência Ideológica

A principal contribuição deste trabalho reside no desenvolvimento de um algoritmo que transforma a saída do modelo K-means (o agrupamento ideológico) em uma métrica de **Aderência Ideológica** (AI) contínua e interpretável.

1) *Definição do Voto Esperado*: Após a clusterização da matriz senador-votação pelo K-means, cada um dos K clusters (C_j) representa uma **posição ideológica latente**. O centróide do cluster (μ_j) corresponde ao vetor de votos médios do grupo em todas as votações. Para definir o **Voto Esperado** ($\hat{v}_j$) desse grupo, o centróide é binarizado (ou trinarizado) por meio de um limiar (τ).

O **Voto Esperado do Cluster** ($\hat{v}_j^{(i)}$) para uma votação i é dado por:

$$\hat{v}_j^{(i)} = \begin{cases} +1 & \text{se } \mu_j^{(i)} > \tau \\ -1 & \text{se } \mu_j^{(i)} < -\tau \\ 0 & \text{se } -\tau \leq \mu_j^{(i)} \leq \tau \end{cases}$$

onde τ é um limiar de neutralidade definido empiricamente neste estudo como $\tau = 0.1$. Este limiar estabelece uma zona de neutralidade mais robusta, assegurando que apenas tendências majoritárias claras no cluster sejam classificadas como Voto Esperado (+1 ou -1), enquanto médias próximas a zero (indicativas de dispersão interna no grupo) permanecem classificadas como neutras.

2) *Cálculo da Aderência Ideológica (AI)*: A métrica AI quantifica a coerência do senador i em relação à posição ideológica ideal de seu grupo C_{ideal} . Essa aderência é calculada utilizando a **Similaridade de Cosseno** entre o vetor de voto real do senador (x_i) e o vetor de voto esperado de seu cluster ($\hat{v}_{\text{ideal}}$), sendo o cluster C_{ideal} aquele ao qual o senador foi atribuído pelo K-means.

A Similaridade de Cosseno é definida como:

$$AI_i = \text{Similaridade}(x_i, \hat{v}_{\text{ideal}}) = \frac{x_i \cdot \hat{v}_{\text{ideal}}}{\|x_i\| \|\hat{v}_{\text{ideal}}\|}$$

O resultado é um valor contínuo que varia de -1 (totalmente oposto ao voto esperado) a +1 (aderência perfeita), oferecendo um índice robusto de quão bem o parlamentar se alinha ao seu agrupamento ideológico.

IV. RESULTADOS E DISCUSSÃO

A aplicação do pipeline de orquestração permitiu processar os dados de votações nominais do Senado Federal referente ao ano de 2023. A seguir, detalham-se as etapas de redução de dimensionalidade, a determinação do número ótimo de clusters e a análise aprofundada da aderência ideológica.

A. Pré-processamento e Redução de Dimensionalidade

A coleta inicial retornou 141 votações. Após a filtragem metodológica — removendo votações de homenagens, pesar e aquelas com unanimidade (baixa variância) —, restaram 35 votações significativas para a análise. O dataset final contou com 81 senadores ativos (participação superior a 50%).

A análise descritiva revelou uma esparsidade de 17,60%, indicando um preenchimento consistente da matriz de votos. A aplicação da Análise de Componentes Principais (PCA) reduziu as 35 dimensões originais (votações) para 19 componentes principais, preservando 95% da variância explicada dos dados.

B. Determinação do Número de Clusters (K)

Para definir o número ideal de agrupamentos, o algoritmo K-Means foi executado com K variando de 2 a 10. As métricas de validação são detalhadas na Tabela I e visualizadas na Figura 1.

Tabela I
MÉTRICAS DE VALIDAÇÃO PARA DIFERENTES VALORES DE K

K	Inércia	Silhueta	Davies-Bouldin
2	1671.65	0.3205	1.2530
3	1375.97	0.2439	1.4711
4	1253.96	0.1948	1.7596
5	1190.74	0.1977	1.7831




Figura 1. Comportamento das métricas de validação. Nota-se que $K=3$ mantém estabilidade antes da queda acentuada de desempenho em $K=4$.

A análise da Figura 1 revela que, embora $K = 2$ apresente os melhores indicadores absolutos (sugerindo polarização binária), a transição para $K = 3$ não representa uma perda estrutural crítica. O índice de Silhueta em $K = 3$ (0.2439) permanece significativamente superior ao patamar observado em $K = 4$ (0.1948), onde ocorre uma degradação acentuada da coesão dos grupos.

Portanto, $K = 3$ configura-se como um ponto de inflexão: ele oferece uma redução substancial na Inércia (de 1671 para 1375) em comparação a $K = 2$, sem sofrer a pulverização excessiva observada em $K \geq 4$. Essa característica matemática

valida a escolha manual de três clusters, permitindo capturar a complexidade do espectro político (Governo, Oposição e Centro) que seria ignorada em uma abordagem puramente binária.

C. Caracterização dos Agrupamentos

Com $K = 3$, os perfis foram definidos como:

- **Cluster 0 (Governo):** 25 membros, alta coesão (Aderência média: 0.471). Predominância de PT, PSD e MDB.
- **Cluster 1 (Oposição):** 27 membros, média coesão (Aderência média: 0.419). Predominância de PL, PP e Republicanos.
- **Cluster 2 (Centro/Independente):** 29 membros, baixa coesão (Aderência média: 0.258). Grupo heterogêneo com membros de PSD, União e Podemos.

D. Análise de Aderência Ideológica (AI)

A métrica de Aderência Ideológica (AI) permitiu classificar os senadores quanto à fidelidade ao comportamento médio de seu grupo.

A Tabela II apresenta os 15 parlamentares com maior aderência. Nota-se que senadores do PP e PL dominam o topo da lista de fidelidade no Cluster 1, enquanto o PT e aliados demonstram forte alinhamento no Cluster 0. O senador Luis Carlos Heinze (PP) obteve a maior aderência absoluta (0.7588).

Tabela II
TOP 15 PARLAMENTARES COM MAIOR ADERÊNCIA

Parlamentar	Partido	Cluster	Aderência (AI)
Luis Carlos Heinze	PP	1	0.7588
Eliziane Gama	PSD	0	0.6857
Wilder Moraes	PL	1	0.6583
Tereza Cristina	PP	1	0.6564
Beto Faro	PT	0	0.6560
Randolfe Rodrigues	REDE	0	0.6560
Fabiano Contarato	PT	0	0.6560
Paulo Paim	PT	0	0.6560
Jussara Lima	PSD	0	0.6534
Rogério Carvalho	PT	0	0.6527
Augusta Brito	PT	0	0.6477
Rogério Marinho	PL	1	0.6358
Romário	PL	1	0.6209
Professora Dorinha Seabra	UNIÃO	2	0.5852
Marcelo Castro	MDB	0	0.5735

Por outro lado, a Tabela III destaca os parlamentares com menor aderência. É notável a presença massiva de membros do Cluster 2 (Centro) nesta lista. Senadores como Oriovisto Guimarães e Laércio Oliveira apresentaram valores de aderência negativos, indicando que seus votos frequentemente divergem do centroide do seu próprio grupo, validando a hipótese de que o "Centro" não opera como um bloco monolítico, mas sim como uma zona de convergência flutuante.

Tabela III
TOP 15 PARLAMENTARES COM MENOR ADERÊNCIA

Parlamentar	Partido	Cluster	Aderência (AI)
Oriovisto Guimarães	PODEMOS	2	-0.1426
Laércio Oliveira	PP	2	-0.1348
Vanderlan Cardoso	PSD	2	-0.1241
Alan Rick	UNIÃO	2	-0.0243
Soraya Thronicke	UNIÃO	2	0.0045
Zequinha Marinho	PL	2	0.0252
Rodrigo Pacheco	PSD	2	0.0745
Carlos Viana	PODEMOS	2	0.0921
Styvenson Valentim	PODEMOS	2	0.0938
Alessandro Vieira	PSDB	2	0.1268
Marcio Bittar	UNIÃO	1	0.1372
Marcos Rogério	PL	1	0.1794
Marcos do Val	PODEMOS	1	0.1836
Mara Gabrilli	PSD	2	0.1862
Sergio Moro	UNIÃO	1	0.2130

V. CONCLUSÃO

O presente trabalho atingiu seu objetivo central ao desenvolver e aplicar uma metodologia baseada em Inteligência Artificial para mensurar a aderência ideológica no Senado Federal. A utilização do algoritmo K-Means, combinada com métricas de validação e uma análise qualitativa do cenário político, permitiu transcender a análise puramente estatística, oferecendo uma interpretação computacional da dinâmica parlamentar.

Os resultados obtidos ratificam a hipótese de que a polarização política brasileira, embora matematicamente binária (como sugerido pelos índices de Silhueta para $K = 2$), exige uma modelagem tricotômica para representar a realidade fática. A decisão estratégica de fixar $K = 3$ revelou-se acertada ao isolar um terceiro agrupamento ("Centro") cuja característica definidora não é a coesão, mas a dispersão. Enquanto os clusters de Governo e Oposição apresentaram altas taxas de aderência ideológica (médias de 0.47 e 0.41, respectivamente), o Cluster 2 demonstrou uma aderência significativamente menor (0.25) e diversos valores negativos. Isso valida computacionalmente o conceito de "Centrão" como uma zona de convergência flutuante, e não como um bloco ideológico monolítico.

A principal contribuição técnica deste estudo é a formalização da métrica de **Aderência Ideológica (AI)**. Ao quantificar a fidelidade do parlamentar em uma escala contínua, o sistema oferece uma ferramenta objetiva para identificar tanto os líderes de núcleo duro (como demonstrado no Cluster 1) quanto os parlamentares pendulares.

A. Limitações e Desafios

Uma limitação inerente ao estudo foi definir o limiar de neutralidade (τ) e a escolha do número de clusters exigiu uma intervenção humana supervisionada sobre o modelo não supervisionado. Embora matematicamente justificada pela estabilidade da silhueta em $K = 3$, essa etapa sublinha que a IA, neste contexto, atua melhor como uma ferramenta de suporte à decisão do analista político do que como um oráculo totalmente autônomo.

B. Trabalhos Futuros

Para extensões futuras, sugere-se a aplicação desta metodologia em uma série temporal longitudinal, abrangendo múltiplas legislaturas, para visualizar a migração de parlamentares entre clusters (mudança de aderência) ao longo do tempo. Outra via promissora é a integração de técnicas de Processamento de Linguagem Natural (PLN) para correlacionar a aderência ideológica votada (o que o senador faz) com a aderência discursiva (o que o senador fala em tribuna), permitindo identificar dissonâncias entre o discurso e a prática legislativa.

Em suma, a ferramenta desenvolvida demonstra que a aplicação de aprendizado de máquina em dados governamentais abertos é um caminho viável e robusto para aumentar a transparência e a compreensibilidade do complexo jogo democrático.

REFERÊNCIAS

- [1] SARPA, M.; RAMOS NOVAIS, P. *Repositório de Código Fonte: Análise de Votação Parlamentar com IA*. GitHub, 2025. Disponível em: <<https://github.com/Sarpa-m/IA2>>.
- [2] RIBEIRO, T. D. *Por que um deputado é indisciplinado?: uma análise das votações nominais na câmara dos deputados entre os anos de 2015 e 2022*. 2023. Dissertação (Mestrado em Administração Pública) – Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa, Brasília, 2023.
- [3] LEITE, L.; TRENTO, S. Análise de votações nominais do legislativo brasileiro utilizando componentes principais. *Leviathan: Cadernos de Pesquisa Política*, n. 12, p. 120-163, 2016.
- [4] LIMA, W. P. C. *Uma análise de partidos políticos baseada em discursos no congresso nacional brasileiro*. 2023. Dissertação (Mestrado em Ciência da Computação) – Centro Federal de Educação Tecnológica Celso Suckow da Fonseca, Rio de Janeiro, 2023.
- [5] ROUSSEEUW, P. J. Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis. *Journal of Computational and Applied Mathematics*, v. 20, p. 53-65, 1987.
- [6] KREUCH, M. A. *Desenvolvimento de solução para visualização e análise de votações políticas*. 2024. Trabalho de Conclusão de Curso (Graduação em Ciências da Computação) – Universidade Federal de Santa Catarina, Florianópolis, 2024.